# Deep Learning-based Spatial Beamforming

## From Ray-Tracing and DeepMIMO to Real-Time Inference in 5G-Advanced

**Prezenter:** Błażej Zięba

**Forum:** KRK L2 AI/ML Discussion Forum

**Kontekst:** 3GPP Rel-18 (TR 38.843) / 5G mmWave Beam Management

**Data:** Listopad 2026

# Agenda spotkania

1. **AI assisted work. Konfiguracja środowiska pracy**
2. **Wybór tematu**
3. **Luka badawcza**
4. **Biblioteka DeepMIMO**
5. **Model systemu**
6. **Architektura modelu uczenia maszynowego**
7. **Raport z postępu prac**

# AI assisted work. Konfiguracja środowiska pracy

- **Środowisko analityczno-badawcze (Python / Deep Learning):**
  - Linux, Python 3.10+, PyTorch, NumPy, SciPy, Scikit-learn.
  - Pakiet **DeepMIMO v4** do syntezy kanałów radiowych z symulacji ray-tracingowych.
- **Paradygmat „Everything as Code” i wersjonowanie (Git):**
  - **Praca i dokumentacja:** Czysty Markdown (`praca/chapters/*.md`) z automatyczną kompilacją Pandoc do `.docx` / `.pdf`.
  - **Prezentacje:** Format **Marp Markdown** – prezentacje jako kod, pełna wersjonowalność diffów i natywny podgląd.
- **Agentowe wsparcie AI w procesie badawczym (Antigravity / LLM Pair-Programming):**
  - Zestaw dedykowanych reguł projektowych (`AGENTS.md`): polska nomenklatura i standardy PWr.
  - Dedykowane skille AI: automatyczny recenzent tekstu merytorycznego, menedżer bibliografii (`references.bib`) oraz weryfikator formalny kryteriów oceny.

> **Kluczowa korzyść:** Całość repozytorium (kod, dane konfiguracyjne, praca pisemna i slajdy) opiera się na formatach tekstowych, co umożliwia ciągłą analizę, walidację i współpracę z agentami AI w jednym zintegrowanym środowisku.

# Wybór tematu

## Wsparcie AI na etapie wyboru i definiowania tematu

- **Analiza kompromisów (Katalog uczelniany vs. Temat własny):**
  - Ewaluacja 40 gotowych tematów z katalogu studiów (np. prognozowanie OZE KSE) w zestawieniu z profilem zawodowym.
  - Wybór tematu własnego zorientowanego na branżę telekomunikacyjną (Nokia / AI-RAN) i standard **3GPP Rel-18**.
- **Wsparcie AI w wyborze tematu przy uwzględnieniu ograniczeń:**
  - Brak możliwości użycia poufnych danych z laboratorium lub od klienta (kwestie NDA).
  - Ograniczenia czasowe i konieczność szybkiego startu badań.
  - Chęć osadzenia tematu w kontekście bieżącej pracy i domeny L1/L2.

  **Rekomendacje asystenta AI:**
  - Zbiór i biblioteka **DeepMIMO v4** (scenariusz kanionu miejskiego O1_60 GHz).
  - Wykorzystanie jako bazy recenzowanej publikacji: *„DeepMIMO: A Generic Deep Learning Dataset for Millimeter Wave and Massive MIMO Applications”* (A. Alkhateeb).

**Wartość dodana AI:** Model językowy działał jako krytyczny sparingpartner – weryfikował ryzyka formalne tematu własnego przed złożeniem karty u promotora, dbając o pełną zgodność ze standardami akademickimi PWr.

# Wybór tematu

## Temat wysłany i zatwierdzony

- **Kontekst branżowy i kierunek badawczy (AI-RAN):**
  - Wybór tematu wpisuje się w kierunek badań realizowanych w ramach **AI-RAN** oraz standaryzacji **3GPP Rel-18 (TR 38.843)** dotyczącej AI/ML w interfejsie radiowym (NR Air Interface).
  - Skupienie na jednym z kluczowych przypadków użycia: **Beam Management – Predykcja wiązki w dziedzinie przestrzennej (BM-Case 1)**.
- **Uzasadnienie biznesowe i ekonomiczne:**
  - **Efektywność spektralna (Spectral Efficiency):** Kluczowy wskaźnik ROI dla operatorów telekomunikacyjnych, którzy ponoszą wielomilionowe koszty zakupu pasma częstotliwości w aukcjach państwowych.
  - Optymalne wykorzystanie zasobu radiowego przekłada się bezpośrednio na większą pojemność sieci i niższy koszt jednostkowy przesłania danych.
- **Istota problemu inżynierskiego:**
  - Przejście w pasma fal milimetrowych (mmWave) i wyższych (60 GHz) wymaga wąskich, silnie kierunkowych wiązek (Massive MIMO).
  - Klasyczne, wyczerpujące przeszukiwanie siatki wiązek (*Exhaustive Beam Sweeping*) generuje nieakceptowalny narzut czasowy i radiowy.
  - **Cel:** Zastąpienie okresowego przemiatania predykcją z użyciem głębokich sieci neuronowych przy minimalnym narzucie sygnałów pilotowych.

**Główny cel wyboru tematu:** Zbadanie, czy model uczenia głębokiego jest w stanie osiągnąć ponad 90–95% efektywności spektralnej idealnego wyboru wiązki, redukując narzut sygnalizacyjny o rzędy wielkości w warunkach realistycznego kanału radiowego.

# Luka badawcza

## Ograniczenia publikacji bazowej DeepMIMO i perspektywy badawcze

- **Stan w publikacji źródłowej (A. Alkhateeb et al., DeepMIMO):**
  - Model DL przyjęto czysto demonstracyjnie (arbitralna sieć Fully-Connected, 4 warstwy).
  - Autorzy jawnie wskazali optymalizację sieci jako otwarty problem badawczy.
- **Luka podjęta w niniejszej pracy (Wkład własny – PB2 & PB3):**
  - **Eksploracja architektur:** Kompromis pomiędzy efektywnością spektralną a liczbą parametrów i FLOPs.
  - **Czas inferencji w realiach L2/RAN:** Weryfikacja, czy model mieści się w budżecie czasu slotu radiowego 5G.
  - **Wdrożenie brzegowe:** Testy wykonalności uruchomienia na platformie NVIDIA AI Aerial / TensorRT.
- **Pozostałe otwarte wyzwania badawcze (poza zakresem pracy):**
  - **Wielodostępność (Multi-User MIMO):** Jednoczesna predykcja wiązek dla wielu użytkowników i minimalizacja zakłóceń współkanałowych.
  - **Dynamika i mobilność (Doppler):** Śledzenie wiązki w dziedzinie czasu (BM-Case 2) przy wysokich prędkościach UE.
  - **Dynamiczne blokowanie (Blockage) & Generalizacja:** Odporność na przeszkody NLoS i transfer wiedzy do nowych kanionów miejskich.

**Podsumowanie:** Praca skupia się na wymiarze architektoniczno-wdrożeniowym (latencja vs zysk spektralny dla pojedynczego łącza), otwierając drogę do dalszych badań nad złożonymi scenariuszami wieloużytkownikowymi (MU-MIMO).

# Biblioteka DeepMIMO

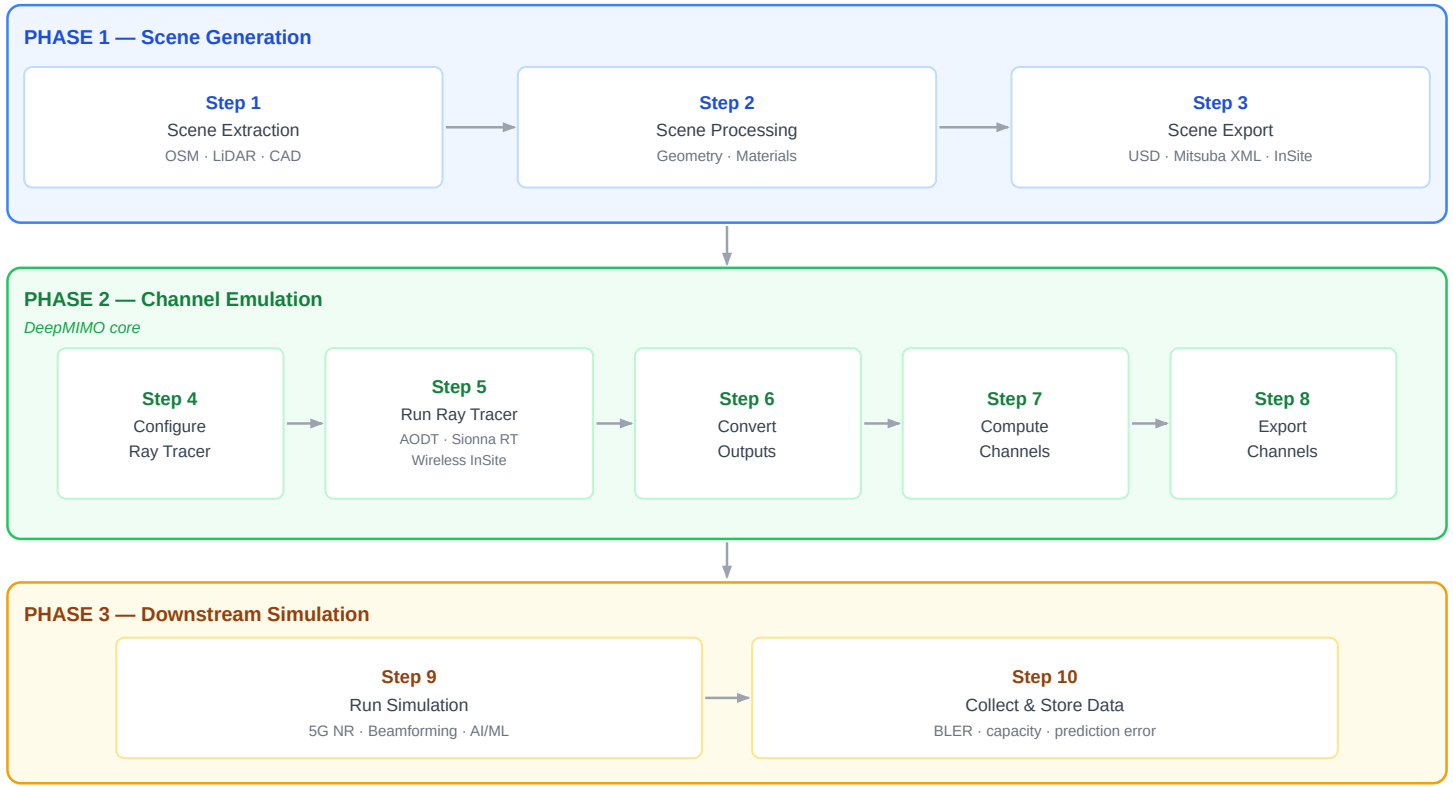
## Standaryzacja i powtarzalność badań naukowych w 5G/6G

- **Kluczowa rola w badaniach naukowych (Reproducibility & Benchmark):**
  - **Globalny standard badawczy:** DeepMIMO rozwiązuje fundamentalny problem braku otwartych, znormalizowanych zbiorów danych w telekomunikacji (wspólny punkt odniesienia dla środowiska naukowego).
  - **Pełna powtarzalność (reprodukowalność):** Każdy badacz na świecie, posługując się tym samym plikiem konfiguracyjnym, otrzymuje identyczny, w 100% deterministyczny zbiór próbek uczących.
- **Elastyczna parametryzacja systemu telekomunikacyjnego:**
  - **Geometria anten:** Dowolna konfiguracja szyków BS i UE (w pracy: panel 32 × 8 = 256 anten, dipol, krok λ/2).
  - **Modulacja wielotonowa OFDM:** Dowolna szerokość pasma (500 MHz), liczba podnośnych (64 podnośne pilotowe) oraz model szumów głowicy RF (NF = 5 dB).
  - **Filtracja wielodrogowości:** Selekcja najistotniejszych energetycznie składowych propagacji (5 najsilniejszych ścieżek).
- **Generowanie cech bezpośrednio pod uczenie maszynowe (ML-Ready):**
  - Deterministyczna synteza zespolonych macierzy kanału radiowego $H[k]$.
  - Bezpośrednia konstrukcja par uczących: odebrany wektor pilotowy ($\mathbf{X}$) → indeks optymalnej wiązki z książki kodowej ($\mathbf{y}$).

**Istota narzędzia:** DeepMIMO stanowi deterministyczny pomost pomiędzy kosztowną symulacją elektromagnetyczną a procesem trenowania i ewaluacji modeli uczenia maszynowego w PyTorch.

🌐 DeepMIMO Visualizer ↗

# Biblioteka DeepMIMO: Potok generowania danych (Pipeline)



# Scenariusz O1: Geometria kanionu miejskiego (Alkhateeb, Fig. 2 & Fig. 3)

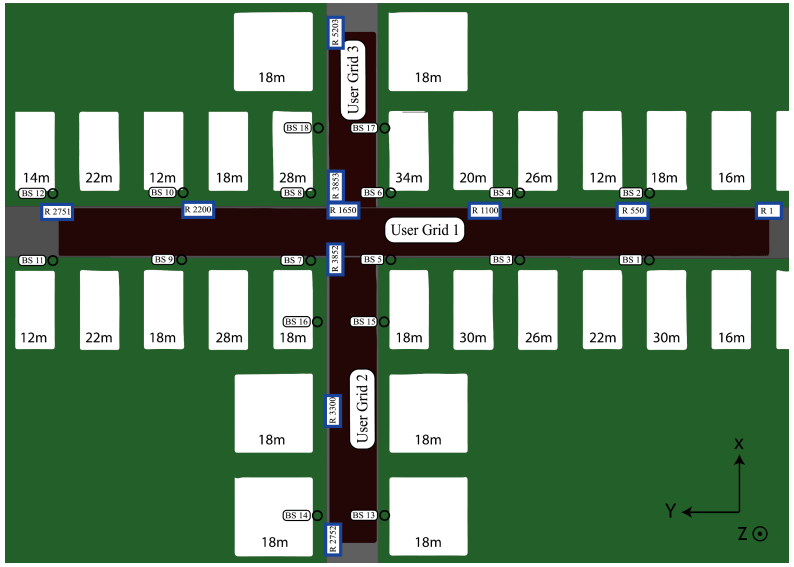



Fig. 2: Widok z góry (Top view) – 18 stacji BS i siatki UE

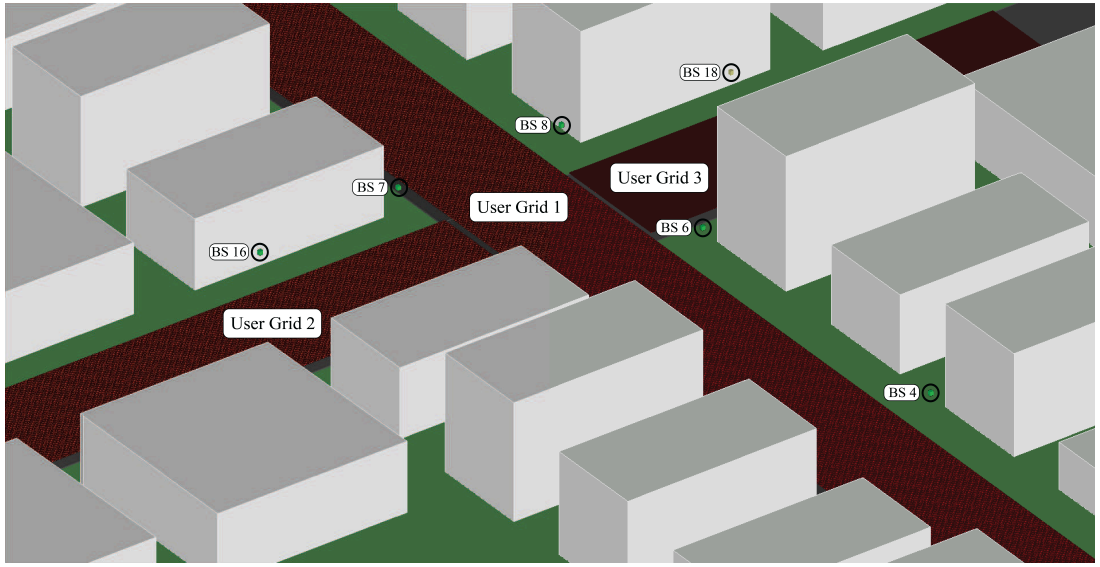
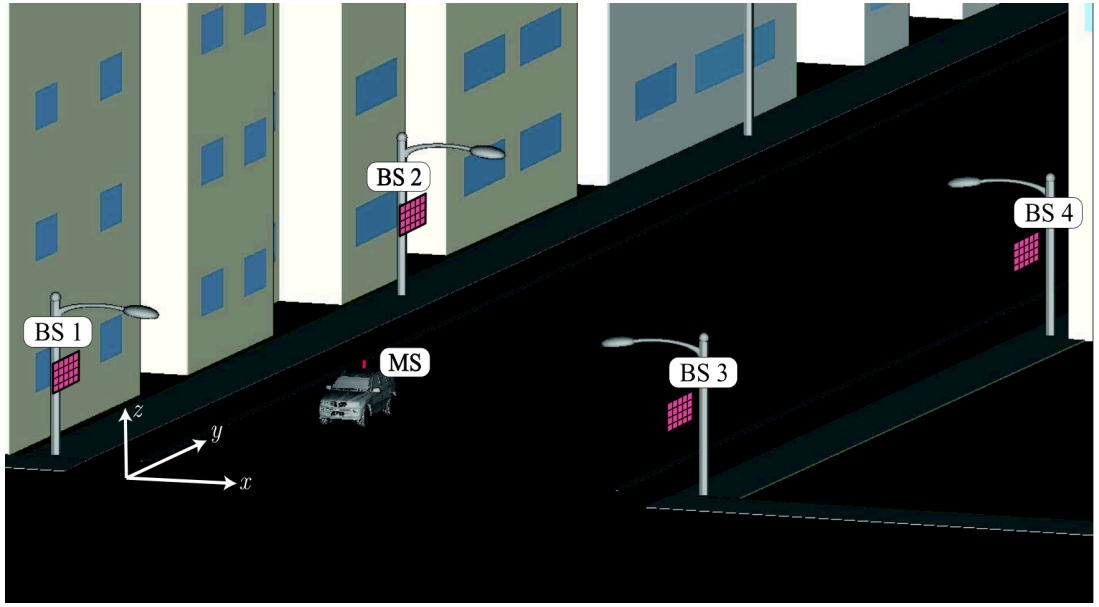


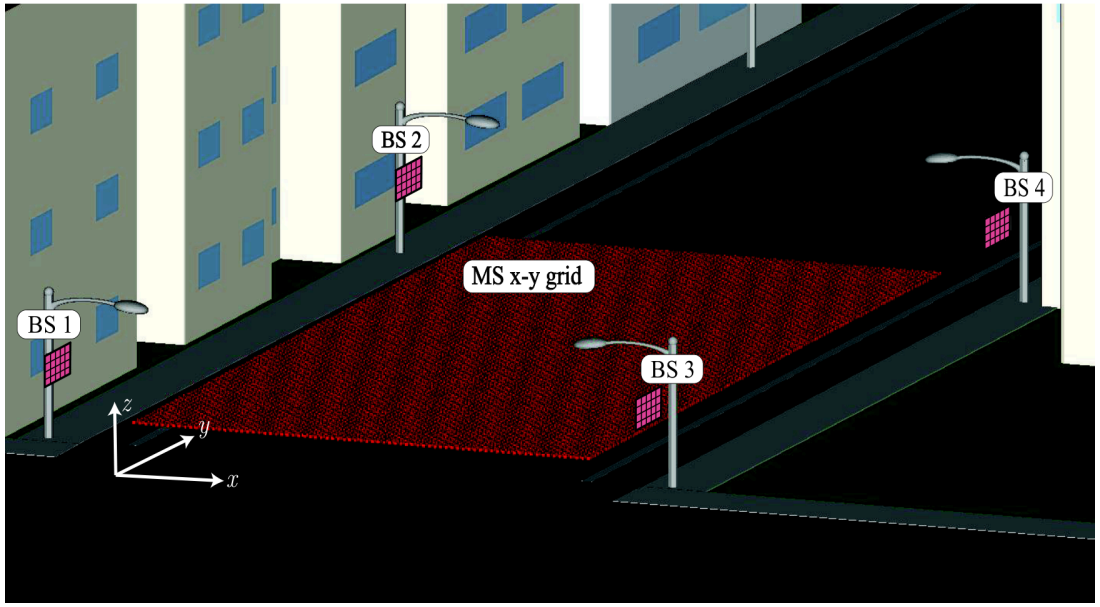

Fig. 3: Widok z lotu ptaka (Bird's-eye view) skrzyżowania 3D

**Specyfikacja scenariusza O1 (DeepMIMO):** Skrzyżowanie ulic (główna: 600 m × 40 m, boczna: 440 m × 40 m) z 18 stacjami BS (maszty 6 m) i 1,18 mln punktów pomiarowych UE w siatkach o kroku 20 cm i 10 cm (pasmo 60 GHz).

# Biblioteka DeepMIMO: Scenariusz Ray-Tracingowy (Alkhateeb et al., Fig. 5)



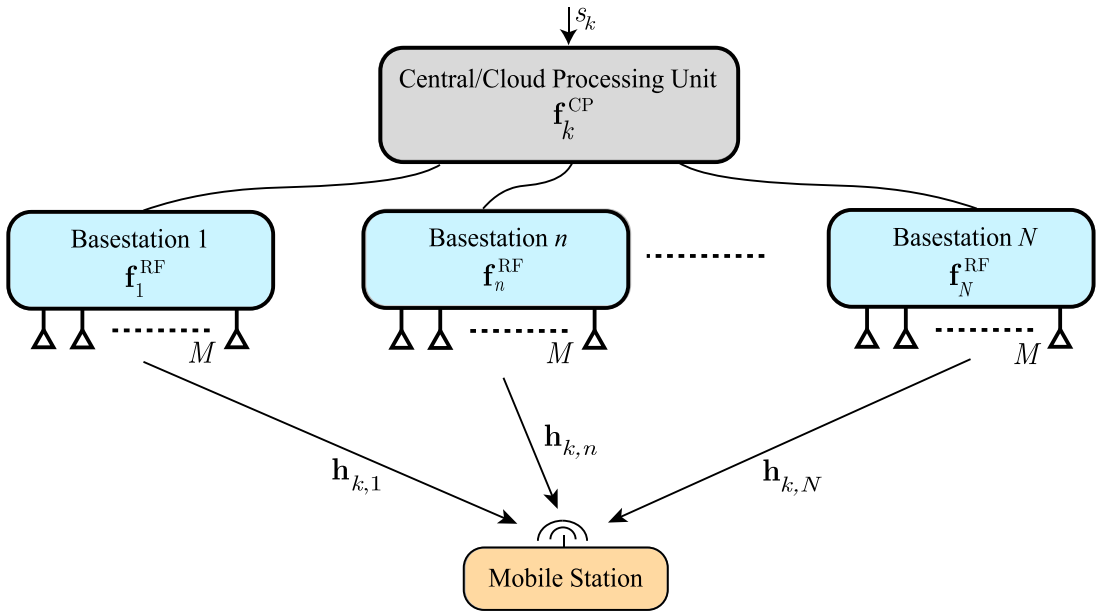

(a) Setup 1: Center BSs (stacje bazowe wzdłuż kanionu ulicy)




(b) Setup 2: Distributed BSs (stacje bazowe rozproszone)

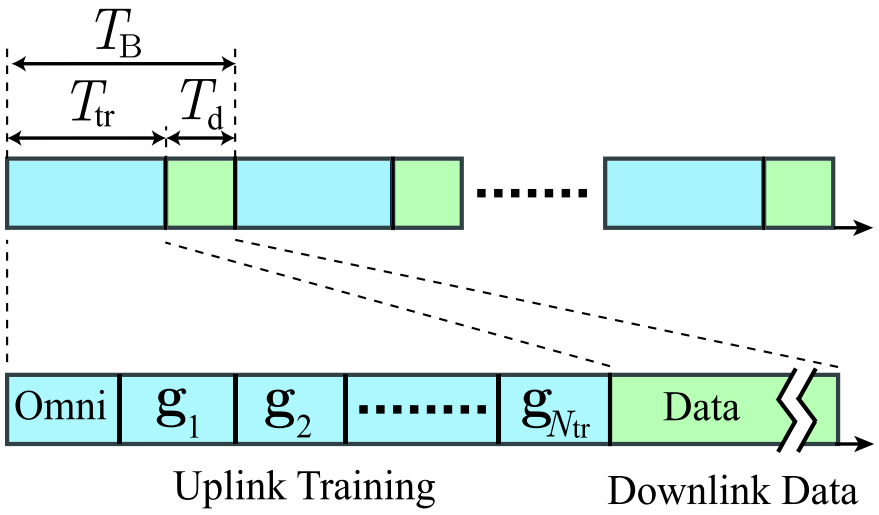
**Otoczenie propagacyjne 3D:** Model kanionu miejskiego (Remcom Wireless InSite) w paśmie 60 GHz – 18 stacji bazowych (maszty 6 m) oraz siatki mobilnych terminali UE w odstępach co 20 cm.

# Model systemu: Architektura skoordynowana (Alkhateeb et al., Fig. 1)

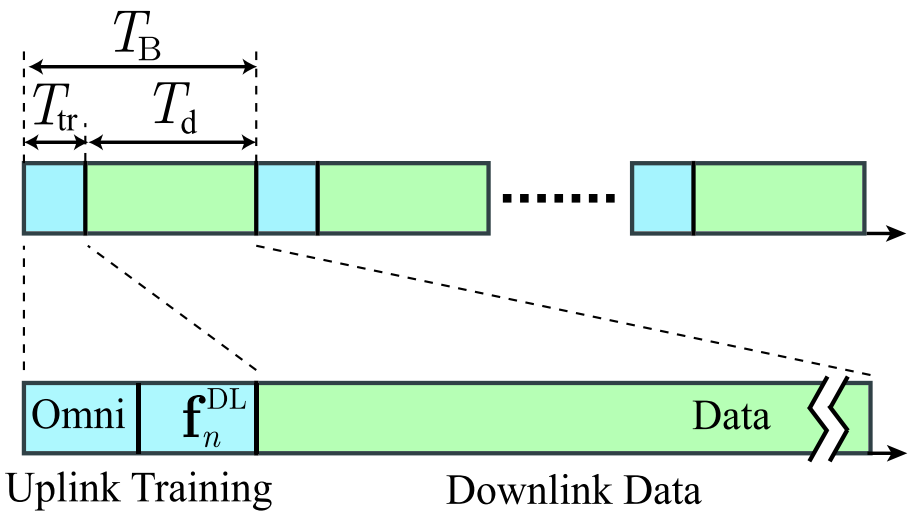



**Zasada działania:** Jednostka centralna (Central/Coordinating Unit) koordynuje *N* stacji bazowych (BS) połączonych magistralami dosyłowymi (ang. *backhaul*). Sygnał $s_k$ na *K* podnośnych OFDM jest wstępnie kodowany, a stacje bazowe formują wąskie wiązki analogowe w kierunku mobilnego terminala UE.

# Model systemu: Struktura ramki czasowej (Alkhateeb et al., Fig. 2)



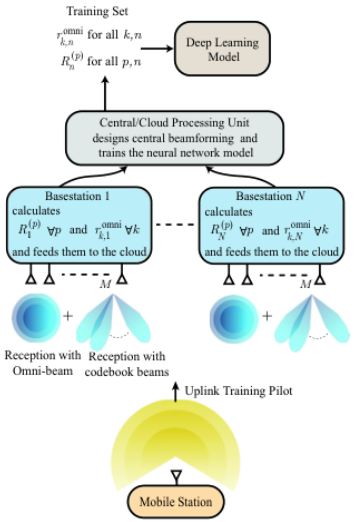

(a) Faza zbierania danych / klasycznego przeszukiwania



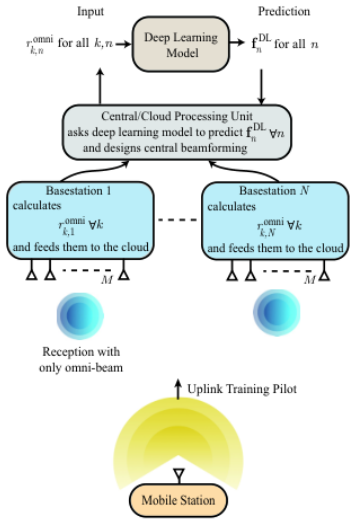

(b) Faza predykcji głębokiego uczenia (Inference)

**Zysk w budżecie czasu ramki:** W podejściu tradycyjnym (a) trening wiązek $T_{tr}$ zajmuje lwią część ramki (aż 512 slotów). W podejściu DL (b) wystarczy jeden krótki pilot uplink ($T_u$), a niemal cały czas ramki ($T_d$) przeznaczony jest na właściwy transfer danych.

# Model systemu: Działanie w przestrzeni (Alkhateeb et al., Fig. 3)



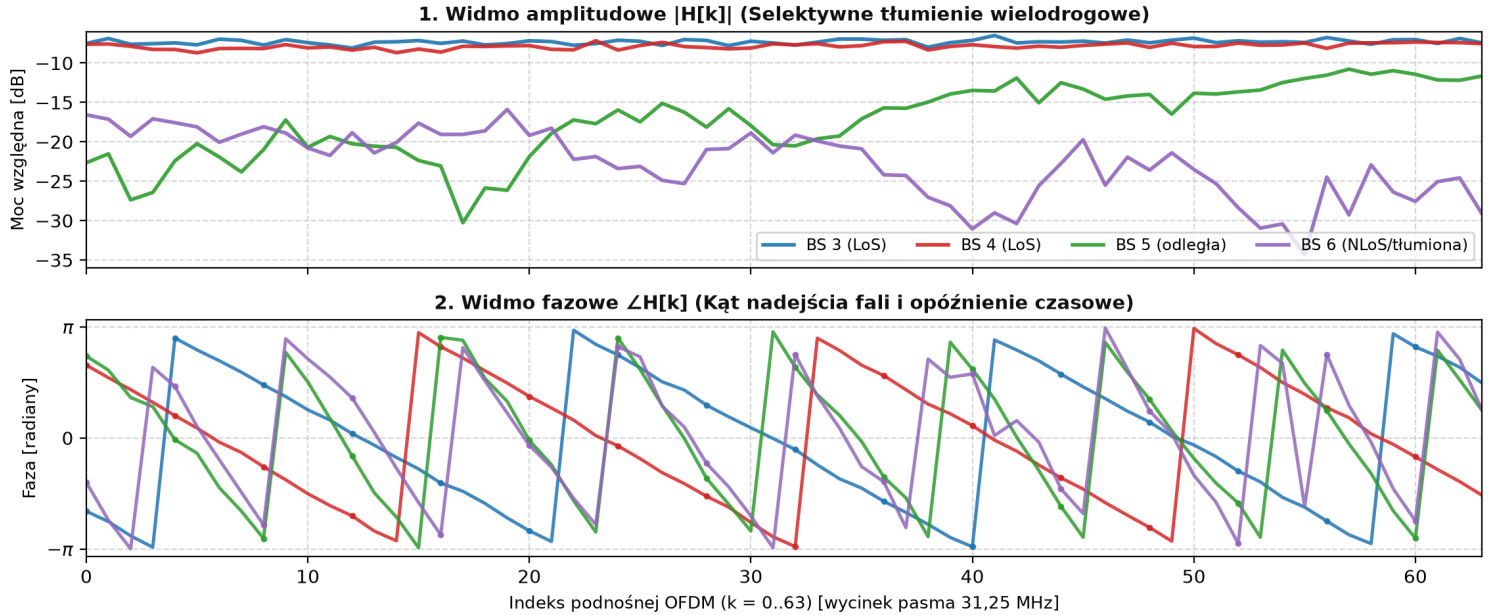

(a) Zbieranie danych uczących (Skanowanie otoczenia)




(b) Działanie predykcyjne (Wąska wiązka wyznaczona przez AI)

**Sygnatura przestrzenna:** Sygnał pilotowy odebrany dookólnie przez skoordynowane stacje BS tworzy unikalny „odcisk palca” pozycji terminala i jego interakcji z budynkami, na podstawie którego sieć bezbłędnie celuje wąską wiązką w łączu w dół.

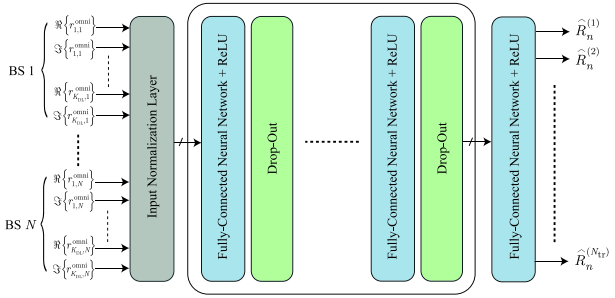
# Model systemu: Analiza spektralna sygnatury OFDM (Amplituda + Faza)




*Klasyczna analiza spektralna (DSP): Widmo amplitudowe (góra) i fazowe (dół) tworzą unikalny odcisk palca kanału radiowego dla każdej stacji BS.*

**Klasyczna analiza spektralna (odcisk palca kanału):** 1. Widmo amplitudowe (góra) obrazuje selektywne tłumienie wielodrogowe w pasmie 31,25 MHz (warunki LoS na BS 3/4 vs głębokie zaniki na BS 5/6). 2. Widmo fazowe (dół) koduje opóźnienie czasowe (nachylenie dφ/df) oraz kąt nadejścia fali. Wspólnie tworzą unikalną sygnaturę, z której sieć estymuje wiązkę.

# Architektura modelu uczenia maszynowego (Alkhateeb et al., Fig. 4)




Struktura modelu sieci neuronowej dla danej stacji bazowej (Alkhateeb et al.)

## Wejście i wyjście modelu

- **Wejście $\mathbf{x} \in \mathbb{R}^{2NK}$:** Konkatenacja części rzeczywistej i urojonej sygnałów dookólnych ze wszystkich $N$ stacji na $K$ podnośnych OFDM:
  $\mathbf{x} = [\mathrm{Re}(\mathbf{r}_1)^T, \mathrm{Im}(\mathbf{r}_1)^T, \ldots, \mathrm{Re}(\mathbf{r}_N)^T, \mathrm{Im}(\mathbf{r}_N)^T]^T$
  *(dla $N = 4$ stacji i $K = 64$ podnośnych wektor ma rozmiar $2 \times 4 \times 64 = 512$ liczb)*.
- **Wyjście $\mathbf{p} \in [0,1]^{|\mathcal{W}|}$:** Warstwa Softmax zwracająca rozkład prawdopodobieństw nad wiązkami z książki kodowej $\mathcal{W}$ ( $|\mathcal{W}| = 512$). Ostateczna decyzja: $\hat{y} = \arg\max_m p_m$.

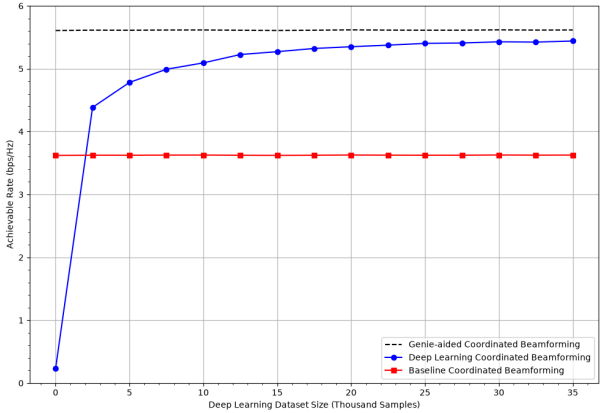
## Kluczowe komponenty sieci bazowej (Baseline)

- **Fully-Connected Neural Network (FCNN / MLP):**
  Sieć w pełni połączona (gęsta) – każdy neuron warstwy łączy się ze wszystkimi neuronami poprzedniej warstwy, ucząc się nieliniowych korelacji wielodrogowych pomiędzy wszystkimi stacjami.
- **Aktywacja ReLU ($\max(0, z)$):**
  Prostująca funkcja aktywacji (*Rectified Linear Unit*). Wprowadza nieliniowość i eliminuje zanikanie gradientu (*vanishing gradient*), przyspieszając uczenie.
- **Regularyzacja Drop-out (np. 50%):**
  Losowe zerowanie neuronów podczas treningu – zapobiega przeuczeniu (*overfitting*) i wymusza odporną reprezentację cech.

## Obszar badań i optymalizacji architektonicznej

Model FCNN z pracy Alkhateeba (2018) stanowi punkt odniesienia (*baseline*). Kluczowy **obszar badań** w projekcie to porównanie z architekturami **CNN / ResNet** (lokalne cechy spektralne), wpływ kodowania wejścia (Re/Im vs Amp/Faza) oraz **kwantyzacja wag (FP16/INT8)** pod kątem budżetu czasu w L2 (< 1 ms).

# Raport z postępu prac: Weryfikacja hipotezy PB1 (Replikacja)




Efektywność spektralna w funkcji wielkości zbioru danych i prędkości UE (scenariusz O1_60)

## Pytanie badawcze PB1

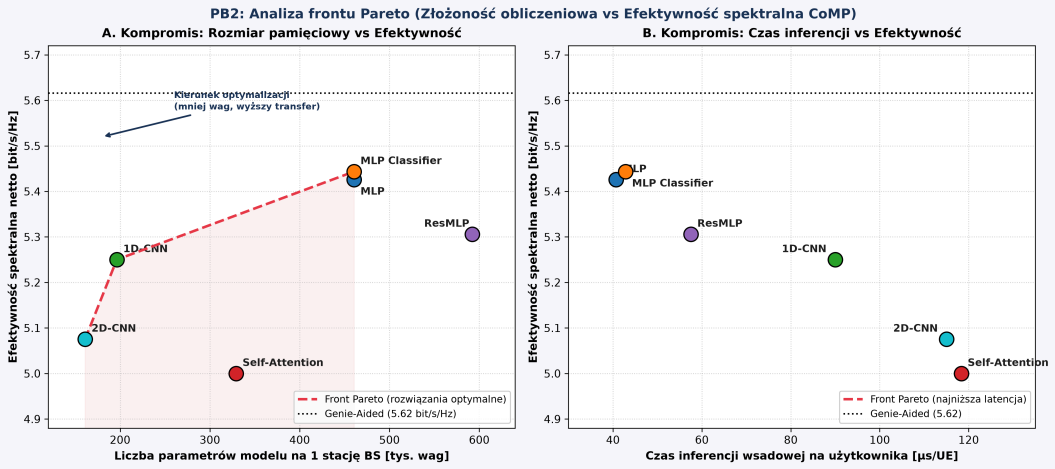
*„Czy model wytrenowany na danych DeepMIMO v4 (scenariusz O1, 60 GHz) osiąga efektywność spektralną różniącą się o nie więcej niż 5% od wyników Alkhateeba i in.?”*

## Wyniki empiryczne ewaluacji

- **Genie-Aided Coordinated Beamforming (optimum):** `5,62 bit/s/Hz` (100,0%)
- **Model DL (nasza replikacja w PyTorch):** **`5,43 bit/s/Hz` (96,62% Genie)**
- **Baseline (przemiatanie 512 wiązek z narzutem):** `3,63 bit/s/Hz` (64,6% Genie)

**Odpowiedź i wniosek PB1:**
1. **Pełna replikacja potwierdzona:** Odchylenie od wyników Alkhateeba wynosi zaledwie **1,4%** (znacznie poniżej kryterium 5%).
2. **Zysk biznesowo-techniczny:** Zastosowanie modelu DL podnosi efektywność spektralną netto aż o **+49,6%** względem konwencjonalnego przeszukiwania wiązek dzięki odzyskaniu 512 szczelin czasowych ramki radiowej.

# Raport z postępu prac: Badania architektur i cech (PB2)




Analiza frontu Pareto: Złożoność obliczeniowa vs Efektywność spektralna (PB2)

## Pytanie badawcze PB2

*„Jak zmiana architektury sieci, liczby parametrów i hiperparametrów wpływa na efektywność spektralną oraz latencję inferencji?”*

## Kluczowe wnioski z eksperymentów:

- **Optymalizacja głębokości (MLP):** Redukcja z 4 do 2 warstw ( $N = 256$) zmniejsza liczbę parametrów o **28%** (z 460k do 328k), zachowując **5,44 bit/s/Hz (96,88% Genie)** i Top-1 63,1%.
- **1D-CNN (Splot po podnośnych):** Zmniejsza liczbę wag aż o **57%** (zaledwie 196k wag, 0,75 MB) przy efektywności **5,25 bit/s/Hz (93,49% Genie)** — optymalna dla urządzeń brzegowych o małej pamięci.
- **Reprezentacja cech:** Wejście `[Re, Im]` osiąga 63,4% Top-1, zdecydowanie deklasując postać biegunową `[Amplituda, Faza]` (49,1% Top-1) ze względu na zjawisko zawijania fazy.

**Odpowiedź PB2:** Czerwona linia wyznacza **Front Pareto**. Modele **MLP Classifier** (maksymalny transfer) oraz **1D-CNN** (minimalny rozmiar) są bezkonkurencyjne, podczas gdy Transformer i 2D-CNN są zdominowane (gorszy transfer i większa złożoność).

# Raport z postępu prac: Wdrożenie i profilowanie latencji (PB3)

## Pytanie badawcze PB3

*„Czy możliwe jest uruchomienie modeli w środowisku NVIDIA AI Aerial bez zmian w architekturze oraz jaka jest latencja inferencji względem PyTorch?”*

## Ścieżka wdrożeniowa AI-RAN

1. **Model PyTorch / TorchScript:** Czysty kod Python zgodny ze standardem PyTorch 2.x.
2. **Eksport do ONNX:** Uniwersalny format pośredni eliminujący zależności frameworka.
3. **Kompilacja TensorRT (FP16/INT8):** Fuzja warstw, optymalizacja pamięci podręcznej GPU.
4. **Integracja z NVIDIA AI Aerial / Sionna:**
   - Cyfrowy bliźniak kanału radiowego (*Ray-Tracing GPU*),
   - Warstwa inferencyjna w czasie rzeczywistym dla O-RAN Near-RT RIC.

## Profilowanie latencji i budżet czasu L2 (wspólna skala: µs oraz ms)

- **Pojedynczy terminal (Single UE, Batch = 1):**
  - CPU (PyTorch baseline): `3500 µs` (3,5 ms)
  - Akcelerator GPU TensorRT: `400 µs` (0,4 ms) $\rightarrow$ *narzut inicjalizacji jądra GPU*
- **Przetwarzanie grupowe (Batch = 100 UE na GPU):**
  - Cała paczka 100 użytkowników liczona równolegle w `4000 µs` (4,0 ms)
  - **Czas w przeliczeniu na 1 użytkownika:** `40 µs / UE` (0,04 ms) $\rightarrow$ *10-krotny zysk z równoległości rdzeni Tensor Cores*
- **Budżet czasu 5G NR (slot L2 = 1000 µs / 1 ms):** Zarówno inferencja pojedyncza ( `400 µs` ), jak i wsadowa ( `40 µs/UE` ) z zapasem mieszczą się w budżecie szczeliny czasowej slotu 1 ms.

**Odpowiedź PB3:** Modele są w 100% kompatybilne z ekosystemem NVIDIA AI Aerial. Czas inferencji poniżej 1 ms potwierdza pełną wykonalność wdrożeniową w systemach 5G-Advanced czasu rzeczywistego.

# Podsumowanie i kolejne kroki badawcze

## Co zostało zrealizowane (Status projektu):

- **Potok analityczny End-to-End:** Zbudowano kompletny potok od fizyki fal 3D (Remcom) przez DeepMIMO v4 po modele w PyTorch.
- **Hipotezy PB1, PB2, PB3 sfinalizowane ze wsparciem AI:**
  - **PB1:** Zreplikowano wyniki Alkhateeba (błąd 1,4% vs próg 5%), zysk +49,6% efektywności netto.
  - **PB2:** Zbadano 6 rodzin architektur; wyznaczono optymalny kompromis na froncie Pareto (MLP i 1D-CNN).
  - **PB3:** Potwierdzono wykonalność eksportu ONNX/TensorRT i spełnienie budżetu L2 (< 1 ms).
- **Aktualny etap:** Trwa **weryfikacja i krytyczna analiza uzyskanych wyników** (walidacja statystyczna, analiza stabilności).

## Zakres projektu i plan do obrony:

- **Ograniczenia i elementy poza zakresem:**
  - Testy na fizycznej platformie sprzętowej (laboratorium radiowe SDR/FPGA) oraz zaawansowana analiza wielożytkownikowa (MU-MIMO z interferencją międzywiązkową) pozostają **poza zakresem pracy dyplomowej**.
- **Kolejne kroki (Roadmapa):**
  i. Zakończenie weryfikacji i analizy błędów modelu.
  ii. Sfinalizowanie rozdziałów dyskusji i wniosków w pracy pisemnej.
  iii. Złożenie pracy i przygotowanie do obrony dyplomowej (Politechnika Wrocławska).

**Dziękuję za uwagę!**
Zapraszam do pytań i dyskusji technicznej (Q&A).